PÍLDORA · M2 DATA ANALYTICS & MACHINE LEARNING

Evaluación de modelos y métricas de rendimiento

¿Cómo sabemos si un modelo es bueno?

Juan Carlos E · 11 de noviembre de 2026

AGENDA

Qué vamos a ver hoy

Bloque	Qué veremos	Tiempo
Contexto	El proceso completo y dónde encaja la evaluación	4 min
Clasificación	Matriz de confusión, métricas con mini ejercicios, ROC-AUC y multiclase	20 min
Regresión	MAE, MSE, RMSE y R^2, una celda por métrica	6 min
Elegir métrica	Qué métrica usar y cuándo	3 min
Caso Titanic	**Cuatro modelos juzgados con métricas, de principio a fin**	**9 min**
Cierre	Ideas clave	3 min
Kahoot	Repaso jugando	15 min

CONTEXT · THE FULL PROCESS

From a question to a working model

PICK THE METRIC HERE

1. Goal

What we want to predict and which mistake costs more

ALREADY SEEN

2. Data

Get the dataset: the Titanic CSV

ALREADY SEEN

3. EDA

Explore and understand the data

12/11 · 13/11

4. Prepare

Fill missing values and turn text into numbers

10/11

5. Split

Train to study, test for the exam

09/11

6. Train

The model learns from train: `fit()`

TODAY

7. Evaluate

Metrics on test, compared with a dummy model

17/11 · 18/11

8. Improve

Another model, another threshold, other settings

AT THE END

9. Deploy

Put it to work and check it keeps getting it right

↺

Trial and error: repeat 4 → 8 until we meet the goal

LA IDEA

Evaluar es comparar predicción y realidad

Pasajero	Realidad	Predicción	¿Acierta?
#1	Sobrevive	Sobrevive	**Sí**
#2	Muere	Muere	**Sí**
#3	Sobrevive	Muere	**No**
#4	Muere	Sobrevive	**No**
#5	Muere	Muere	**Sí**

Lo hacemos con los pasajeros de **test**: el modelo no los vio al entrenar.

No todos los fallos son iguales: el #3 y el #4 se equivocan de forma distinta.

CLASIFICACIÓN BINARIA · LA BASE DE TODO

La matriz de confusión

Clasificación binaria: el modelo elige entre 2 clases · 0 = muere (negativo) · 1 = sobrevive (positivo)



Positivo / Negativo
lo que **predijo** el modelo

Verdadero / Falso
si **acertó** o no

Ojo: en la lección la visteis con TP arriba a la izquierda. scikit-learn empieza por el 0:

```
[[TN, FP], [FN, TP]]
```

Azul: aciertos · Naranja: errores · 179 pasajeros de test

File Edit View Insert Cell Kernel Widgets Help

Matriz de confusión en scikit-learn

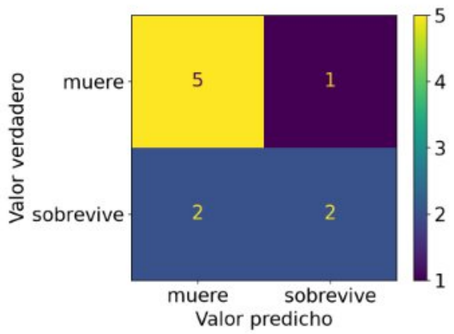
Clasificación binaria: 2 clases · 0 = muere · 1 = sobrevive · mini ejercicio de 10 pasajeros

In [1]:
```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

y_verdadero = [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
y_predicho  = [0, 0, 0, 0, 0, 1, 1, 1, 0, 0]

print(confusion_matrix(y_verdadero, y_predicho))
disp = ConfusionMatrixDisplay.from_predictions(
    y_verdadero, y_predicho, display_labels=["muere", "sobrevive"])
disp.ax_.set(xlabel="Valor predicho", ylabel="Valor verdadero")
```

Out[1]:
```
[[5 1]
 [2 2]]
```



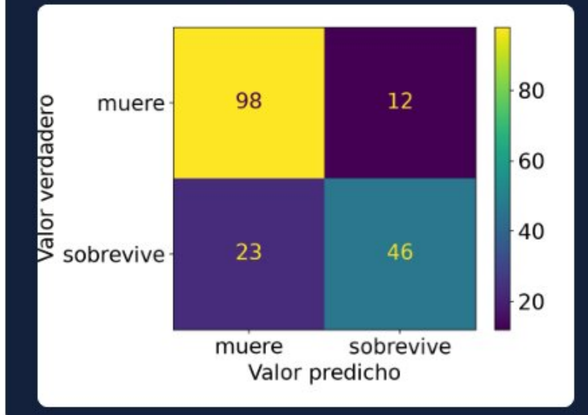
CÓMO SE LEE

```
[[TN, FP],
 [FN, TP]]
```

Filas = valor verdadero · columnas = valor predicho

5 muertos bien · 1 falsa alarma · 2 supervivientes perdidos · 2 encontrados

CON EL TITANIC COMPLETO (179 PASAJEROS)



Mismo orden que la diapositiva anterior: primero el 0 («muere»), después el 1 («sobrevive»).

File Edit View Insert Cell Kernel Widgets Help

Accuracy (exactitud)

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: 10 pasajeros · 0 = muere · 1 = sobrevive

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{2 + 5}{10} = 0{,}7$$

Aciertos entre total: los **FP** y los **FN** cuentan igual, no distingue el tipo de error

In [2]:
```
from sklearn.metrics import accuracy_score

y_verdadero = [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
y_predicho = [0, 0, 0, 0, 0, 1, 1, 1, 0, 0]
accuracy_score(y_verdadero, y_predicho)
```

Out[2]:
```
0.7
```

A MANO

Aciertos: 5 + 2 = **7 de 10**
7 / 10 = **0,7**

CON EL TITANIC COMPLETO (179 PASAJEROS)

(46 + 98) / 179 = **0,80**

La más intuitiva... y la más engañosa.

CUIDADO

La trampa del accuracy

Modelo «todos mueren»

61 %

de accuracy en el Titanic sin mirar ni un solo dato (110 / 179)

Detector «nada es fraude»

99 %

de accuracy si el 99 % de las operaciones son legales… y no detecta ni un fraude

«Todos mueren»: $\text{Accuracy} = \frac{0 + 110}{179} = 0{,}61$ pero $\text{Recall} = \frac{0}{0 + 69} = 0$

Con clases desequilibradas, el accuracy engaña. Cómo arreglarlo: mañana, 12/11.

File Edit View Insert Cell Kernel Widgets Help

Precision

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: 10 pasajeros · 0 = muere · 1 = sobrevive

$$\text{Precision} = \frac{TP}{TP + \mathbf{FP}} = \frac{2}{2 + \mathbf{1}} = 0{,}67$$

Precision mira los **FP** (falsos positivos): dijo «sobrevive» y murió

In [3]:
```
from sklearn.metrics import precision_score

y_verdadero = [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
y_predicho = [0, 0, 0, 0, 0, 1, 1, 1, 0, 0]
precision_score(y_verdadero, y_predicho)
```

Out[3]:
```
0.6666666666666666
```

A MANO

Dijo «sobrevive» 3 veces y acertó 2

2 / 3 = **0,67**

CON EL TITANIC COMPLETO (179 PASAJEROS)

46 / (46 + 12) = **0,79**

Importa si el falso positivo sale caro: filtro de spam.

File Edit View Insert Cell Kernel Widgets Help

Recall (sensibilidad)

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: 10 pasajeros · 0 = muere · 1 = sobrevive

$$\text{Recall} = \frac{TP}{TP + \mathbf{FN}} = \frac{2}{2 + \mathbf{2}} = 0{,}5$$

Recall mira los **FN** (falsos negativos): sobrevivió y dijo «muere»

In [4]:
```
from sklearn.metrics import recall_score

y_verdadero = [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
y_predicho = [0, 0, 0, 0, 0, 1, 1, 1, 0, 0]
recall_score(y_verdadero, y_predicho)
```

Out[4]: 0.5

A MANO

Sobrevivieron 4 y encontró 2
2 / 4 = **0,5**

CON EL TITANIC COMPLETO (179 PASAJEROS)

46 / (46 + 23) = **0,67**

Importa si el falso negativo sale caro:
cáncer, fraude.

EL DILEMA · PRECISION VS RECALL

Si subes una, baja la otra

UMBRAL BAJO

Dice «sí» con poco

$$\text{Recall} = \frac{TP}{TP + FN}$$ **Pocos FN** → recall alto

$$\text{Precision} = \frac{TP}{TP + FP}$$ **Muchos FP** → precision baja

UMBRAL ALTO

Dice «sí» solo si está seguro

$$\text{Precision} = \frac{TP}{TP + FP}$$ **Pocos FP** → precision alta

$$\text{Recall} = \frac{TP}{TP + FN}$$ **Muchos FN** → recall bajo

Elegir es una decisión de negocio, no matemática.

File Edit View Insert Cell Kernel Widgets Help

F1-score

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: 10 pasajeros · 0 = muere · 1 = sobrevive

$$F1 = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} = \frac{4}{4 + 1 + 2} = 0{,}57$$

F1 mira los dos: **FP** y **FN** · es lo mismo que 2·P·R / (P + R)

In [5]:
```
from sklearn.metrics import f1_score

y_verdadero = [0, 0, 0, 0, 0, 0, 1, 1, 1, 1]
y_predicho = [0, 0, 0, 0, 0, 1, 1, 1, 0, 0]
f1_score(y_verdadero, y_predicho)
```

Out[5]:
```
0.5714285714285714
```

A MANO

2 × 0,67 × 0,5 / (0,67 + 0,5)
= **0,57**

CON EL TITANIC COMPLETO (179 PASAJEROS)

2 × 0,79 × 0,67 / 1,46 ≈ **0,72**

No se deja engañar: si una de las dos es baja, el F1 también.

TU TURNO · EJERCICIO GUIADO · 3 MINUTOS

Mujeres y niños primero: 100 pasajeros

Un modelo predice quién sobrevive. Comparamos con lo que pasó de verdad.

	Dice: sobrevive	Dice: muere
Sobrevivió de verdad	**30** TP	**8** FN
Murió de verdad	**12** FP	**50** TN

1 · Accuracy: ¿cuántos acierta en total?

$$\frac{TP\ (30) + TN\ (50)}{Total\ (100)} = \mathbf{0,80}$$

2 · Precision: si dice «sobrevive», ¿acierta?

$$\frac{TP\ (30)}{TP\ (30) + \mathbf{FP\ (12)}} = \mathbf{0,71}$$

3 · Recall: ¿encuentra a los que sobreviven?

$$\frac{TP\ (30)}{TP\ (30) + \mathbf{FN\ (8)}} = \mathbf{0,79}$$

4 · F1: el equilibrio de los dos

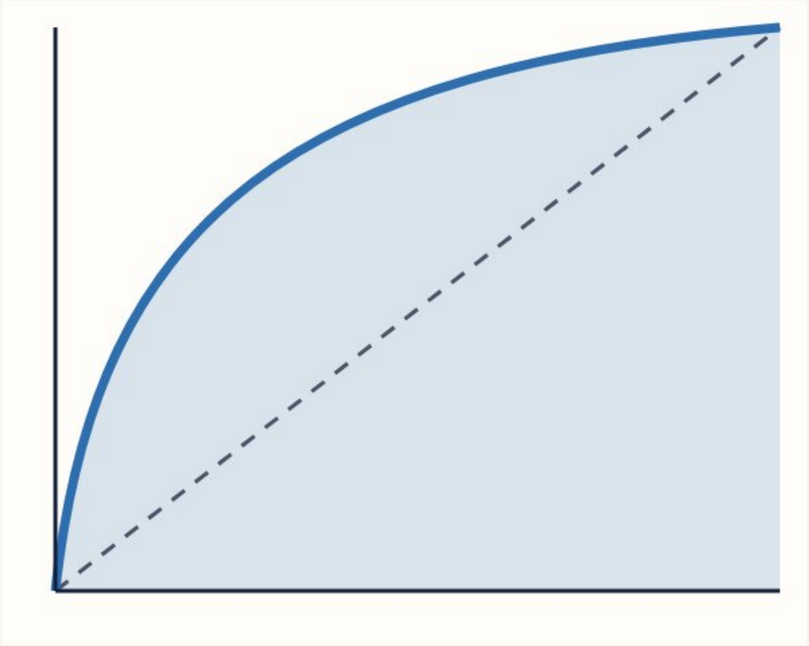
$$\frac{2 \cdot TP\ (60)}{2 \cdot TP\ (60) + \mathbf{FP\ (12)} + \mathbf{FN\ (8)}} = \mathbf{0,75}$$

Reto: **somos el equipo de rescate y queremos encontrar al menos a 8 de cada 10 supervivientes (recall ≥ 0,80). ¿Este modelo lo cumple?**

No, por muy poco: encuentra a 30 de 38 supervivientes → recall 0,79 < 0,80. Se le escapan 8 (los FN).

MÉTRICA 5 · ROC-AUC

Medir el modelo sin depender del umbral



Eje X: falsos positivos · Eje Y: recall
Curva azul: el modelo · Discontinua: el azar

El modelo da una **probabilidad**: «0,8 de sobrevivir».

La **curva ROC** muestra cómo se comporta con **todos** los umbrales.

$$\text{Eje Y (recall)} = \frac{TP}{TP + FN}$$

$$\text{Eje X (falsas alarmas)} = \frac{FP}{FP + TN}$$

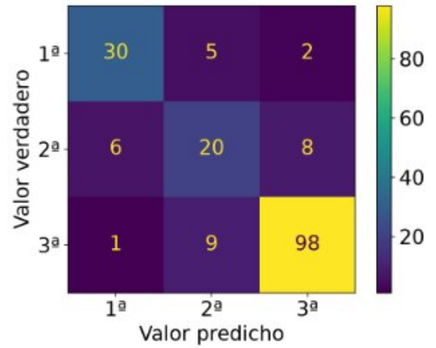
El **AUC** es el área bajo la curva:

0,5 = azar | > 0,8 = bueno | 1 = perfecto

MULTICLASE · PARA VUESTRO PROYECTO

¿Y si hay más de dos clases?

```python
from sklearn.metrics import ConfusionMatrixDisplay, classification_report
disp = ConfusionMatrixDisplay.from_predictions(clase_real, clase_predicha,
    display_labels=["1ª", "2ª", "3ª"])
disp.ax_.set(xlabel="Valor predicho", ylabel="Valor verdadero")
print(classification_report(clase_real, clase_predicha))
```



	precision	recall	f1-score	support
1ª	0.81	0.81	0.81	37
2ª	0.59	0.59	0.59	34
3ª	0.91	0.91	0.91	108
accuracy			0.83	179
macro avg	**0.77**	**0.77**	**0.77**	179
weighted avg	0.83	0.83	0.83	179

Recall por clase = diagonal / total de la fila: $\mathbf{R_1}$ = 30/37 = 0,81 · $\mathbf{R_2}$ = 20/34 = 0,59 · $\mathbf{R_3}$ = 98/108 = 0,91

Macro avg · media simple

$$\frac{R1 + R2 + R3}{3} = 77\ \%$$

Todas las clases pesan igual. Delata a la clase que va mal.

Weighted avg · media ponderada

$$\frac{37 \cdot R1 + 34 \cdot R2 + 108 \cdot R3}{179} = 83\ \%$$

Pesa más la clase con más pasajeros. Puede esconder a la que va mal.

REGRESIÓN · PREDECIR UN NÚMERO

¿Cuánto pagó de billete?

Pasajero	Real	Predicho	Error
A	10 £	15 £	5
B	30 £	25 £	5
C	80 £	60 £	**20**

Columna **Fare** del Titanic. Ya no hay aciertos o fallos: hay errores más grandes o más pequeños.

Las 4 métricas que vamos a ver, una por diapositiva:

MAE · error medio

MSE · error al cuadrado

RMSE · raíz del MSE

R^2 · cuánto explica el modelo

File Edit View Insert Cell Kernel Widgets Help

Error absoluto medio (MAE)

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: precio del billete de 3 pasajeros, en libras

$$\text{MAE} = \frac{\Sigma\,|y - \hat{y}|}{n} = \frac{5 + 5 + 20}{3} = 10$$

Suma los errores sin signo y divide entre **n**, el número de pasajeros

In [6]:
```
from sklearn.metrics import mean_absolute_error

y_verdadero = [10, 30, 80]
y_predicho = [15, 25, 60]
mean_absolute_error(y_verdadero, y_predicho)
```

Out[6]:
```
10.0
```

A MANO

Errores: 5, 5 y 20
(5 + 5 + 20) / 3 = **10**

«De media me equivoco en 10 libras».
La más fácil de explicar.

File Edit View Insert Cell Kernel Widgets Help

Error cuadrático medio (MSE)

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: precio del billete de 3 pasajeros, en libras

$$\text{MSE} = \frac{\Sigma\,(y - \hat{y})^2}{n} = \frac{25 + 25 + \mathbf{400}}{3} = 150$$

Al cuadrado: el error de 20 se convierte en **400** y domina la media

In [7]:
```
from sklearn.metrics import mean_squared_error

y_verdadero = [10, 30, 80]
y_predicho = [15, 25, 60]
mean_squared_error(y_verdadero, y_predicho)
```

Out[7]:
```
150.0
```

A MANO

Errores al cuadrado: 25, 25 y 400
(25 + 25 + 400) / 3 = **150**

El error de 20 pesa 16 veces más que uno de 5. Pero está en libras², difícil de explicar.

File Edit View Insert Cell Kernel Widgets Help

Raíz del error cuadrático medio (RMSE)

y : valor verdadero

$\hat{y}$: valor predicho

Mini ejercicio: precio del billete de 3 pasajeros, en libras

$$\text{RMSE} = \sqrt{\frac{\Sigma\,(y - \hat{y})^2}{n}} = \sqrt{150} \approx 12{,}25$$

La raíz deshace el cuadrado: el error vuelve a estar en libras

In [8]:
```
from sklearn.metrics import root_mean_squared_error

y_verdadero = [10, 30, 80]
y_predicho = [15, 25, 60]
root_mean_squared_error(y_verdadero, y_predicho)
```

Out[8]:
```
12.24744871391589
```

A MANO

$\sqrt{150}$ = **12,2**

Vuelve a estar en libras. Si es bastante mayor que el MAE (10), hay algún error grande.

R^2 (coeficiente de determinación)

y : valor verdadero

$\hat{y}$: valor predicho

$\bar{y}$: media de los valores verdaderos

Mini ejercicio: precio del billete de 3 pasajeros, en libras

$$R^2 = 1 - \frac{\Sigma (y - \hat{y})^2}{\Sigma (y - \bar{y})^2} = 1 - \frac{450}{2600} = 0{,}83$$

Arriba: errores de tu modelo · Abajo: errores de predecir siempre la media

In [9]:
```
from sklearn.metrics import r2_score

y_verdadero = [10, 30, 80]
y_predicho = [15, 25, 60]
r2_score(y_verdadero, y_predicho)
```

Out[9]:
```
0.8269230769230769
```

A MANO

Media real ȳ = 40

1 − 450 / 2600 = **0,83**

1 = perfecto · 0 = como predecir siempre la media. Negativo = peor que eso.

CHULETA

Qué métrica usar y cuándo

Situación	Métrica	Fórmula
Clases equilibradas, todos los errores pesan igual	**Accuracy**	(TP + TN) / total
Un falso positivo sale caro (spam)	**Precision**	TP / (TP + FP)
Un falso negativo sale caro (cáncer, fraude)	**Recall**	TP / (TP + FN)
Clases desequilibradas, o importan los dos errores	**F1**	2·TP / (2·TP + FP + FN)
Comparar modelos sin fijar un umbral	**ROC-AUC**	área bajo la curva ROC
Regresión: error fácil de explicar	**MAE**	$\Sigma \lvert y - \hat{y} \rvert / n$
Regresión: castigar los errores grandes	**RMSE**	$\sqrt{(\Sigma (y - \hat{y})^2 / n)}$
Regresión: cuánta variación explica el modelo	**R^2**	$1 - \Sigma (y - \hat{y})^2 / \Sigma (y - \bar{y})^2$

Mismos nombres en la lección: accuracy = exactitud · precision = precisión · recall = sensibilidad (TPR)

CASO PRÁCTICO · DE PRINCIPIO A FIN

¿Qué modelo elegimos para el Titanic?

Cuatro candidatos, un objetivo y las métricas como juez.

Todos los resultados son reales, calculados antes de la clase con los 179 pasajeros de test.

CASO TITANIC · PASO 1 · OBJETIVO

Primero, qué queremos

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

Somos el **equipo de rescate**. El modelo nos dice a quién buscar primero.

Lo peor: no buscar a alguien que está vivo **(FN)**.

También malo: buscar a demasiados que no están **(FP)**: no damos abasto.

EL CRITERIO, ANTES DE ENTRENAR

Recall ≥ 0,80

encontrar al menos 8 de cada 10 supervivientes

Precision ≥ 0,60

que al menos 6 de cada 10 búsquedas valgan la pena

CASO TITANIC · PASOS 2 A 5 · DATOS, EDA, PREPARAR Y DIVIDIR

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

Lo que ya sabemos del Titanic

2 · DATOS

891

pasajeros. Solo el **38 %** sobrevivió: hay más «muere» que «sobrevive».

3 · EDA

Mujeres: **74 %** sobreviven
Hombres: **19 %**

1ª clase: **63 %**
3ª clase: **24 %**

Pista: el sexo lo explica casi todo.

4 · PREPARAR

Edad: **177** nulos → mediana
Embarque: **2** nulos → moda
Cabina: **687** nulos → fuera

Sexo y puerto, de texto a números.

5 · DIVIDIR

712 / 179

train / test. En test hay **69** supervivientes: los que queremos encontrar.

CASO TITANIC · CANDIDATO 1

«Todos mueren»

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

No mira nada: siempre dice «muere». Es el mínimo que cualquier modelo tiene que superar.

	Dijo: sobrevive	Dijo: muere
Sobrevivió	0 TP	69 FN · se escapan
Murió	0 FP · falsa alarma	110 TN

Accuracy
61 %

Precision
— ✗

Recall
0 % ✗

Suspende

61 % de accuracy sin aprender nada.

No encuentra a **ni un** superviviente: los 69 se escapan.

CASO TITANIC · CANDIDATO 2

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

La regla del EDA: «mujer → sobrevive»

Sin entrenar nada: aplicamos la pista del EDA. Si es mujer, buscarla; si es hombre, no.

	Dijo: sobrevive	Dijo: muere
Sobrevivió	45 TP	24 FN · se escapan
Murió	16 FP · falsa alarma	94 TN

Accuracy	Precision	Recall
78 %	74 % ✓	65 % ✗

Suspende por poco

Una sola regla ya saca un 78 %. Es la referencia a batir.

Pero se escapan **24** supervivientes: casi todos, hombres y niños.

CASO TITANIC · CANDIDATO 3

Regresión logística

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

Ahora sí, un modelo entrenado con todas las columnas: clase, sexo, edad, familia, tarifa y puerto.

	Dijo: sobrevive	Dijo: muere
Sobrevivió	46 TP	23 FN · se escapan
Murió	12 FP · falsa alarma	98 TN

Accuracy	Precision	Recall
80 %	79 % ✓	67 % ✗

Mejor… pero suspende

Gana a la regla en accuracy y precision. AUC = 0,84.

Recall 67 %: aún se escapan **23** de 69.

CASO TITANIC · CANDIDATO 4

Árbol de decisión

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

Otro algoritmo. En test saca el mejor accuracy de todos... ¿lo elegimos?

	Dijo: sobrevive	Dijo: muere
Sobrevivió	51 TP	18 FN · se escapan
Murió	14 FP · falsa alarma	96 TN

Accuracy
82 %

Precision
78 % ✓

Recall
74 % ✗

Suspende y es sospechoso

En **train**: 98 % de accuracy. En **test**: 82 %.

Diferencia: **16 puntos**. En vuestro proyecto el límite es **5**.

Se ha aprendido los apuntes de memoria (overfitting, 17/11). Recall 74 %.

CASO TITANIC · PASO 8 · MEJORAR

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

La logística, con el umbral en 0,25

No cambiamos de modelo: le pedimos que diga «sobrevive» con menos seguridad (0,25 en vez de 0,5).

	Dijo: sobrevive	Dijo: muere
Sobrevivió	56 TP	13 FN · se escapan
Murió	33 FP · falsa alarma	77 TN

Accuracy
74 %

Precision
63 % ✓

Recall
81 % ✓

Aprueba

Se escapan **13** en vez de 23. Recall 81 %.

A cambio, más falsas alarmas (33) y el accuracy **baja** al 74 %. Y está bien.

CASO TITANIC · VEREDICTO

Objetivo: recall ≥ 0,80 · precision ≥ 0,60

El elegido tiene el peor accuracy

Candidato	Accuracy	Precision	Recall	¿Cumple?
1 · «Todos mueren»	61 %	—	0 %	✗
2 · Regla «mujer»	78 %	74 %	65 %	✗
3 · Logística (umbral 0,5)	80 %	79 %	67 %	✗
4 · Árbol de decisión	82 %	78 %	74 %	✗
3b · Logística (umbral 0,25)	74 %	63 %	81 %	✓

1. El listón se puso **antes**, en el objetivo.

2. Compara con un modelo tonto y con una regla simple.

3. Si train » test, desconfía.

4. El umbral también se elige.

CIERRE

Tres ideas para llevarse

1

El accuracy puede mentir

Compáralo siempre con un modelo tonto.

2

¿Qué error sale más caro?

Esa pregunta decide entre precision y recall.

3

No hay «mejor métrica»

Hay la adecuada para tu problema.

KAHOOT · 15 MINUTOS

¡Ahora, a jugar!

Entra en kahoot.it e introduce el PIN

PIN: [_____]